



# Redes Neurais Convolucionais na Segmentação Semântica de Imagens Aéreas para o Mapeamento da Cobertura da Terra em Áreas de Proteção Ambiental

Fabricio Bizotto 

 Universidade Tecnológica Federal do Paraná (UTFPR)  
Câmpus Ponta Grossa (PG)  
Departamento Acadêmico de Informática (DAINF)  
Programa de Pós-Graduação em Ciência da Computação (PPG-CC)  
 [mlsguario@utfpr.edu.br](mailto:mlsguario@utfpr.edu.br)  
Orientadora: Profa. Dra. Mauren L Andrade

# Sumário

## 1 Introdução

- **Objetivo Geral**
- Objetivos Específicos
- Trabalhos Relacionados

## 2 Material e Métodos

- Metodologia Proposta
- Estudos sobre a APA-Petrópolis
- Configuração do ambiente de Trabalho
- Aquisição do Conjunto de Dados
- Seleção e Rotulagem
- Implementação e Adaptações na Rede SegNet e U-NET
- Treinamento e Teste

## 3 Resultados e Discussão

- Cenários

## 4 Conclusões

- Descrição das Conclusões Obtidas

# Sumário

## 5 Referências

## 6 Agradecimentos

# Introdução

- Área de Proteção Ambiental (APA)

- ▶ Ferramenta de Conservação da Natureza.
- ▶ Destinada à proteção ambiental e ao uso sustentável dos recursos naturais.
- ▶ Objetivo: Conservação x Desenvolvimento Econômico.
- ▶ Gestão governamental, como o Instituto Chico Mendes de Conservação da Biodiversidade (ICMBio).
- ▶ Regulamenta as atividades humanas de acordo com as características ambientais da região.

## Principais desafios no monitoramento da APA

- Grandes equipes de trabalho especializada
- Deslocamento à regiões de difícil acesso
- Alto custo para manutenção das equipes
- Perigos associados as características de fauna e flora de cada região



# Introdução

- A cobertura e utilização do solo (**Land Use and Land Cover - LULC**)
- Compreender a relação entre cobertura e uso da terra é essencial para gerir os recursos naturais, mitigar as alterações climáticas e proteger a biodiversidade (**ZIN; LIN; 2018**).
- Mudanças antropogênicas abrangem o desflorestamento, desocupação, urbanização, alterações nos tipos de cultivo e adaptações nas práticas utilizadas em cada uso do solo, tais como, técnicas de plantio e sistemas de rotação de cultura florestal (**Peterson et al. (2014)**).

# Introdução

## Sensoriamento Remoto

- Alternativa de baixo custo
- Acesso a base de dados de imagens para diferentes regiões
- Acesso a áreas de difícil acesso via solo
- Estudos começaram a explorar a aplicação das Redes Neurais Convolucionais (RNC) na análise da cobertura da terra com resultados promissores (**HU et al.; 2013**); (**LI et al.; 2020**).

## Possibilidades

- Imagens de satélite disponíveis gratuitamente (baixa resolução)
- VANT (Veículo Aéreo não Tripulado) (custo alto)
- Imagens Aéreas RGB da plataforma Google Earth

# Introdução

## Objetivo Geral

O objetivo geral deste trabalho é o desenvolvimento de uma nova metodologia para segmentação semântica de imagens de sensoriamento remoto do Google a fim de gerar o mapa de cobertura e uso do solo da região da APA-Petrópolis, Rio de Janeiro por meio de RNC



# Introdução

## Objetivos Específicos

Para atender o objetivo geral deste trabalho, foram propostos os seguintes objetivos específicos:

### Objetivos Específicos


- Capturar e rotular imagens de sensoriamento remoto da área de proteção ambiental de Petrópolis, Rio de Janeiro.
- Comparar o desempenho de redes neurais do tipo SegNet e U-NET no conjunto de dados criado.
- Comparar diferentes funções de custo a fim de avaliar a que melhor se adapte ao conjunto de dados.
- Utilizar métricas para analisar e comparar o desempenho dos modelos.
- Comparar os resultados obtidos com trabalhos relacionados.

# Introdução

## Trabalhos Relacionados

1. Construção de mapas digitais a partir de imagens de satélite, utilizando a arquitetura U-Net com EfficientNet-B0 como codificador e decodificador **(NGUYEN-KHANH; NGUYEN-NGOC-YEN; DINH-QUOC, 2021)**.

Figura 2 – Resultado da segmentação semântica no conjunto de dados do Google com a arquitetura proposta.



Fonte: Adaptado de (NGUYEN-KHANH; NGUYEN-NGOC-YEN; DINH-QUOC, 2021).

# Introdução

## Trabalhos Relacionados

2. Aplicação de RNC, na tarefa de segmentação semântica de imagens obtidas por sensoriamento remoto. Duas arquiteturas de RNC, SegNet e U-net, são aprimoradas por meio da introdução de *index pooling* para melhorar essas arquiteturas, permitindo a preservação de informações espaciais cruciais durante a ampliação da resolução. **(ALAM et al., 2021)**.

Figura 3 – Resultado da segmentação semântica.




Fonte: Adaptado de (ALAM et al., 2021).

# Introdução

## Trabalhos Relacionados

3. Redes U-Net para segmentar estufas agrícolas de plástico em imagens de sensoriamento remoto de alta resolução. A abordagem foi dividida em três etapas: coleta e anotação de imagens, treinamento da rede U-Net e pós-processamento para remover elementos confundíveis com as estufas (**CHEN et al., 2021**).

Figura 4 – Dificuldade em extrair estufas densamente distribuídas.



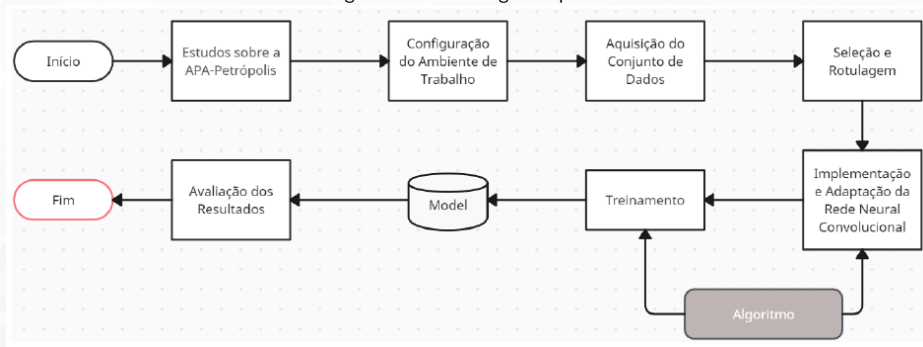
Fonte: (CHEN et al., 2021).

# Material e Métodos

## Metodologia Proposta

A Fig. 5 apresenta a metodologia utilizada para a realização dos objetivos propostos.

Figura 5 – Metodologia Proposta.

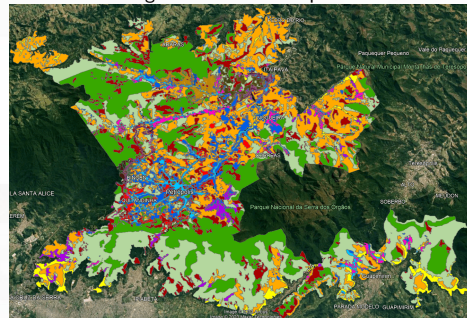


Fonte: Autoria Própria.

## Estudos sobre a APA-Petrópolis

- $\approx$  60.000 hectares (5,69%) da Mata Atlântica.
- Região urbanizada.
- Plano de manejo que define ações e restrições.
- Petrópolis e municípios adjacentes.

Figura 6 – APA-Petrópolis.



Fonte: Adaptado de **Google Earth**; 2023empty citation.

# Material e Métodos

## Configuração do ambiente de Trabalho

- **Processador:** Intel(R) Xeon(R) CPU E5-2666 v3 @ 2.90GHz 2.90 GHz;
- **Memória RAM:** 32 GB;
- **Placa de Vídeo:** NVIDIA GIGABYTE RTX 3060 EAGLE OC – 12GB dedicada;
- **Sistema Operacional:** Microsoft Windows 10 PRO 64 bits.

A Tab. 1 apresenta o conjunto de ferramentas utilizado durante o trabalho.

Tabela 1 – Conjunto de Ferramentas Utilizadas.

Python	(VAN ROSSUM, 2009)
PyTorch	(PASZKE et al., 2017)
Cuda Toolkit	(NVIDIA CORPORATION, 2023)
Miniconda	(INC, 2023)
ArcGis Pro (parceria com UFMS)	(ESRI INC., 2023)
Computer Vision Annotation Tool	(CVAT.AI, 2023)

Fonte: Autoria própria.



# Material e Métodos

## Aquisição do Conjunto de Dados

- Plataforma Google Earth (ArcGis Pro).
- Entre Maio/2022 e Dezembro/2022.
- Seleção aleatória da área.

Figura 7 – Demonstração da aquisição do conjunto de dados.



Fonte: Adaptado de **Google Earth**; 2023empty citation.



# Material e Métodos

## Aquisição do Conjunto de Dados

Tabela 2 – Separação das imagens no conjunto de dados.

Grupo	Quantidade
Treinamento	214 ( $\approx 67\%$ )
Teste	42 ( $\approx 13\%$ )
Descontinuadas	66 ( $\approx 20\%$ )
Total	322

Fonte: Autoria própria.

### Mais Detalhes

- RGB (TIFF).
- Resolução padrão de 2048x2048 pixels.

Figura 8 – Amostras do Conjunto de Dados.



Fonte: Adaptado de **Google Earth**; 2023empty citation.

# Material e Métodos

## Seleção e Rotulagem

### Seleção - Rotulagem

- Delimitar as regiões de interesse.
- Definido em conjunto com equipe do ICMBio.
- 8 classes
  - ▶ Área Desenvolvida
  - ▶ Floresta
  - ▶ Sombra
  - ▶ Área em Regeneração
  - ▶ Solo Exposto
  - ▶ Água
  - ▶ Rocha
  - ▶ Agricultura
  - ▶ **Piscina**

Figura 9 – Amostras do Conjunto de Dados por Classe.



Fonte: Adaptado de Google Earth; 2023empty citation.

# Material e Métodos

## Seleção e Rotulagem

### Seleção - Rotulagem

- Auxílio de um profissional do ICMBio.
- Critério rígido.
- Ferramentas
  - ArcGis (semi-automático, manual)
  - CVAT (manual)

Figura 10 – Amostra da imagem original e da imagem rotulada.



Fonte: Autoria própria.

# Metodologia Aplicada no Desbalanceamento de Classes

## Seleção e Rotulagem

- Método proposto por (BRESSAN et al., 2022).
- Calcular o peso para cada classe (treinamento).



$$\varphi(c) = \frac{m}{C * n^c}$$

Tabela 3 – Pesos calculados para o conjunto de treinamento.

Classe	Peso
Área Desenvolvida	1,1472
Floresta	0,3832
Sombra	2,0468
Área em Regeneração	0,4436
Agricultura	1,4859
Rocha	2,4287
Solo Exposto	5,2043
Água	2,0031

Fonte: Autoria própria.

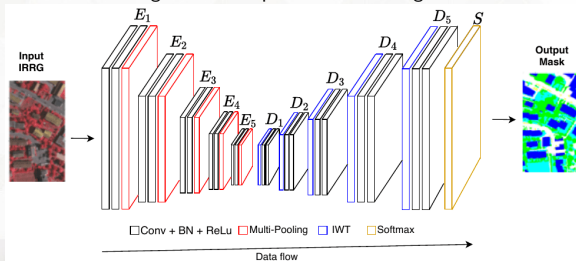
em que  $m$  é o número de pixels de todas as imagens de treinamento,  $C$  é o número de classes, e  $n^c$  é o número de pixels que pertencem à classe  $c$ .

# Material e Métodos

## Implementação e Adaptações na Rede SegNet e U-NET

- **MPSegnet** proposta por **SOUZA BRITO et al.; 2021**
- Uma nova estratégia de multi-pooling, substituindo o max-pooling por *Discrete Wavelet Transform* (DWT) e unpooling por *Inverse Discrete Wavelet Transform* (IWT).
- Conjunto de dados utilizado nos experimentos
  - ▶ 2D Semantic Labeling Contest - Potsdam
  - ▶ IRRG: 3 canais (IR-R-G)

Figura 11 – Arquitetura da MPSegnet.



Fonte: (DE SOUZA BRITO et al., 2021)

# Material e Métodos

## Implementação e Adaptações na Rede SegNet e U-NET

- **U-NET** sugerida no artigo de **Nguyen-Khanh et al. (2021)**empty citation.
- Combinação de **EfficientNet-B0** (TAN; LE, 2019) (ENCODER) para extração de características com **U-NET Ronneberger et al. (2015)**empty citation (DECODER) para reconstrução do mapa de características.
- Conjunto de dados utilizado nos experimentos
  - ▶ Imagens Aéreas (Google Earth - GE)
  - ▶ RGB: 3 canais (*Red-Green-Blue*)

Tabela 4 – Comparativo entre *encoder* e funções de custo.

ENCODER	Parâmetros	Categorical Cross Entropy Loss	Dice Loss	Average Loss
VGG11	32M	1.194	0.770	1.066
ResNet18	18M	1.191	0.770	1.065
EffNet-B0	<b>4M</b>	<b>1.110</b>	<b>0.731</b>	<b>0.997</b>
EffNet-B1	6.5M	1.374	0.806	1.204
EffNet-B2	8M	1.134	0.747	1.018

Fonte: Adaptado de **Nguyen-Khanh et al. (2021)**empty citation.

# Material e Métodos

## Treinamento e Teste

- Conjunto de dados dividido em treinamento e teste (Ver Tabela 2).
- Pré-processamento: Protocolo de **janelas deslizantes** adotado também no trabalho de (DE SOUZA BRITO et al., 2021).
- **10.000** amostras de **256x256**.
- Inicialização dos pesos: Pesos pré-treinados (DENG et al., 2009).

### Treinamento

- Conjunto de dados embaralhado.
- Aumento de dados
  - ▶ **Espelhamento horizontal e vertical**

### Teste

- Conjunto de dados **não** é embaralhado.
- Sem aumento de dados.
- Protocolo de janelas deslizantes com passo de 32 pixels para evitar inconsistências na segmentação, especialmente nas bordas (FARHANGFAR; REZAEIAN, 2019).
- Maior esforço computacional.

# Material e Métodos

Treinamento e Teste - Mais detalhes de implementação.

- **Número de classes:** 8
- **Épocas de treinamento:** 100
- **Tamanho do *batch*:** 8
- **Taxa de aprendizagem:**  $1e-2$ 
  - ▶ **Escalonamento:** redução de 10 vezes nas 25°, 35° e 45° épocas
  - ▶ **Dcaimento:** limitado a  $1e-5$
- **Otimizador:** SGD (*Stochastic Gradient Descent*)
  - ▶ *Momentum*: 0,9
  - ▶ *Weight Decay*:  $1e-5$

## Observações

Os detalhes de implementação acima foram utilizados em ambos os modelos e consideraram as escolhas de de Souza Brito et al. (2021).



# Material e Métodos

## Função de Custo - Entropia Cruzada

Mede a diferença entre a distribuição de probabilidade prevista ( $p_i$ ) e o *ground truth* dos rótulos para a classe ( $y_i$ ), comumente expressa pela Equação 1 (Li et al., 2019).

$$L_{CE} = -\frac{1}{M} \sum_{i=1}^M (y_i^T \log(p_i)) \quad (1)$$

onde  $M$  é o número total de classes,  $L_{CE}$  é a função de entropia cruzada,  $y_i^T$  é o vetor (*ground truth*) transposto de  $y_i$ ,  $p$  é o vetor de probabilidades atribuídas a cada classe.

# Material e Métodos

## Função de Custo - *Focal Loss*

É uma modificação da função de entropia cruzada que visa resolver o problema de desbalanceamento de classes, dando maior peso às classes minoritárias. A função é definida pela Equação 2 (LIN et al., 2017).

$$FL(p_t) = - \sum_{i=1}^C (1 - p_{ti})^{\gamma} \cdot \log(p_{ti}) \quad (2)$$

onde:

- $C$  é o número de classes.
- $p_{ti}$  é a probabilidade prevista da classe verdadeira.
- $\gamma$  é um parâmetro de foco ajustável.
- O termo  $(1 - p_{ti})^{\gamma}$  reduz o peso da perda para exemplos bem classificados, focando mais nos exemplos difíceis e mal classificados.
- Quando  $p_t$  está próximo de 1 (indicando uma previsão confiante e correta), a perda é reduzida.

Isso ajuda a reduzir o impacto de pixels fáceis de classificar e permite que o modelo se concentre mais em regiões desafiadoras.

# Resultados e Discussão

## Cenários

- **Cenário 1:** SegNet Modificada, usando a função de custo **Entropia Cruzada**.
  - ▶ Experimento 1: **pesos iguais (1)**.
  - ▶ Experimento 2: **pesos ponderados**.
  - ▶ Utilização de 9 classes (8 classes + **piscina**).
- **Cenário 2:** SegNet Modificada, usando a função de custo **Entropia Cruzada**.
  - ▶ Experimento 1: **com aumento de dados**.
  - ▶ Experimento 2: **sem aumento de dados**.
  - ▶ Ambos usam pesos ponderados na função de custo.
- **Cenário 3:** U-NET, usando a função de custo **Entropia Cruzada** com pesos ponderados.
  - ▶ Experimento 1: **com aumento de dados**.
  - ▶ Experimento 2: **sem aumento de dados**.
- **Cenário 4:** SegNet Modificada e U-NET, usando a função de custo **Focal Loss**.
  - ▶ Experimento 1: SegNet Modificada **com aumento de dados**.
  - ▶ Experimento 2: U-NET **com aumento de dados**.

# Resultados e Discussão

## Cenários

- **Cenário 1:** SegNet Modificada, usando a função de custo **Entropia Cruzada**.
  - ▶ Experimento 1: **pesos iguais (1)**.
  - ▶ Experimento 2: **pesos ponderados**.
  - ▶ Utilização de 9 classes (8 classes + **piscina**).
- **Cenário 2:** SegNet Modificada, usando a função de custo **Entropia Cruzada**.
  - ▶ Experimento 1: **com aumento de dados**.
  - ▶ Experimento 2: **sem aumento de dados**.
  - ▶ Ambos usam pesos ponderados na função de custo.
- **Cenário 3:** U-NET, usando a função de custo **Entropia Cruzada** com pesos ponderados.
  - ▶ Experimento 1: **com aumento de dados**.
  - ▶ Experimento 2: **sem aumento de dados**.
- **Cenário 4:** SegNet Modificada e U-NET, usando a função de custo **Focal Loss**.
  - ▶ Experimento 1: SegNet Modificada **com aumento de dados**.
  - ▶ Experimento 2: U-NET **com aumento de dados**.

# Resultados e Discussão

## Cenários

- **Cenário 1:** SegNet Modificada, usando a função de custo **Entropia Cruzada**.
  - ▶ Experimento 1: **pesos iguais (1)**.
  - ▶ Experimento 2: **pesos ponderados**.
  - ▶ Utilização de 9 classes (8 classes + **piscina**).
- **Cenário 2:** SegNet Modificada, usando a função de custo **Entropia Cruzada**.
  - ▶ Experimento 1: **com aumento de dados**.
  - ▶ Experimento 2: **sem aumento de dados**.
  - ▶ Ambos usam pesos ponderados na função de custo.
- **Cenário 3:** U-NET, usando a função de custo **Entropia Cruzada** com pesos ponderados.
  - ▶ Experimento 1: **com aumento de dados**.
  - ▶ Experimento 2: **sem aumento de dados**.
- **Cenário 4:** SegNet Modificada e U-NET, usando a função de custo **Focal Loss**.
  - ▶ Experimento 1: SegNet Modificada **com aumento de dados**.
  - ▶ Experimento 2: U-NET **com aumento de dados**.

# Resultados e Discussão

## Cenários

- **Cenário 1:** SegNet Modificada, usando a função de custo **Entropia Cruzada**.
  - ▶ Experimento 1: **pesos iguais (1)**.
  - ▶ Experimento 2: **pesos ponderados**.
  - ▶ Utilização de 9 classes (8 classes + **piscina**).
- **Cenário 2:** SegNet Modificada, usando a função de custo **Entropia Cruzada**.
  - ▶ Experimento 1: **com aumento de dados**.
  - ▶ Experimento 2: **sem aumento de dados**.
  - ▶ Ambos usam pesos ponderados na função de custo.
- **Cenário 3:** U-NET, usando a função de custo **Entropia Cruzada** com pesos ponderados.
  - ▶ Experimento 1: **com aumento de dados**.
  - ▶ Experimento 2: **sem aumento de dados**.
- **Cenário 4:** SegNet Modificada e U-NET, usando a função de custo **Focal Loss**.
  - ▶ Experimento 1: SegNet Modificada **com aumento de dados**.
  - ▶ Experimento 2: U-NET **com aumento de dados**.

Aumento de dados: **Espelhamento horizontal e vertical.**

# Resultados e Discussão

## Cenário 1 - Distribuição de pesos na função de custo

Tabela 5 – Pesos ponderados para a função de custo no cenário 1.

Classe	Peso
Área Desenvolvida	0,9786
Floresta	0,3264
Piscina	51,3827
Sombra	1,7031
Área em Regeneração	0,3702
Agricultura	1,2344
Rocha	2,0176
Solo Exposto	4,8396
Água	10,5859

Fonte: Autoria própria.

### Observações

- **Piscina**: maior peso.
- Os demais cenários consideram os pesos calculados e apresentados na **Tabela 3**.

# Resultados e Discussão

## Cenário 1 - Análise dos Resultados

Tabela 6 – Resultados da SegNet no cenário 1 com pesos iguais.

Classe	Prec	Sens	F1-Score	IoU
Desenvolvida	0.79	0.80	0.80	0.66
Floresta	0.89	0.87	0.88	0.78
Piscina	0.18 <sup>a</sup>	0.89	0.30	0.17
Sombra	0.86	0.80	0.83	0.70
Regeneração	0.73	0.89	0.80	0.66
Agricultura	0.82	0.83	0.82	0.70
Rocha	0.86	0.45	0.59	0.42
Solo Exposto	0.56	0.20	0.29	0.17
Água	0.45	0.06	0.11	0.05
Acurácia	0.81 <sup>b</sup>		IoU	0.48

Fonte: Autoria própria.

<sup>a</sup> Proporção de VP mantida em ambos os experimentos.

<sup>b</sup> Ponderação nos pesos pode ter afetado a acurácia.

Tabela 7 – Resultados da SegNet no cenário 2 com pesos ponderados.

Classe	Prec	Sens	F1-Score	IoU
Desenvolvida	0.71	0.76	0.73	0.57
Floresta	0.89	0.67	0.76	0.61
Piscina	0.18	0.99	0.30	0.18
Sombra	0.60	0.86	0.71	0.55
Regeneração	0.80	0.44	0.56	0.39
Agricultura	0.66	0.76	0.70	0.54
Rocha	0.37	0.69	0.48	0.31
Solo Exposto	0.09	0.40	0.14	0.08
Água	0.46	0.73 <sup>a</sup>	0.56 <sup>b</sup>	0.39 <sup>c</sup>
Acurácia	0.65		IoU	0.40

Fonte: Autoria própria.

<sup>a</sup> Redução significativa nos falsos negativos

<sup>b</sup> Melhor equilíbrio entre precisão e sensibilidade


<sup>c</sup> Melhoria na sobreposição entre *Ground Truth* e previsão na segmentação.



# Resultados e Discussão


## Cenário 1 - Matriz de Confusão

Figura 12 – Matriz de confusão do cenário 1 com pesos iguais.



Fonte: Autoria própria.

Figura 13 – Matriz de confusão do cenário 2 com pesos ponderados.



Fonte: Autoria própria.

# Resultados e Discussão

## Cenário 2 - Análise dos Resultados

Tabela 8 – Resultados da SegNet no cenário 2 com aumento de dados. Tabela 9 – Resultados da SegNet no cenário 2 sem aumento de dados.

Classe	Prec	Sens	F1-Score	IoU
Desenvolvida	0.83	0.77	0.80	0.66
Floresta	0.94	0.77	0.85	0.74
Sombra	0.69	0.93	0.79	0.66
Regeneração	0.83	0.66	0.73	0.58
Agricultura	0.83	0.77	0.80	0.66
Rocha	0.50	0.77	0.61	0.43
Solo Exposto	0.17	0.79	0.28	0.16
Água	0.72	0.89	0.79	0.66
Acurácia	0.76		IoU	0.57

Fonte: Autoria própria.


Classe	Prec	Sens	F1-Score	IoU
Desenvolvida	<b>0.84</b>	<b>0.84</b>	<b>0.84</b>	<b>0.72</b>
Floresta	<b>0.95</b>	0.76	<b>0.85</b>	0.73
Sombra	<b>0.70</b>	0.92	<b>0.80</b>	<b>0.67</b>
Regeneração	<b>0.88</b>	0.65	<b>0.75</b>	<b>0.60</b>
Agricultura	<b>0.72</b>	<b>0.93</b>	<b>0.81</b>	<b>0.69</b>
Rocha	<b>0.55</b>	<b>0.83</b>	<b>0.66</b>	<b>0.50</b>
Solo Exposto	<b>0.27</b>	0.73	<b>0.40</b>	<b>0.25</b>
Água	<b>0.89</b>	<b>0.95</b>	<b>0.92</b>	<b>0.85</b>
Acurácia	0.79		IoU	0.62

Fonte: Autoria própria.

# Resultados e Discussão

## Cenário 2 - Matriz de Confusão

Figura 14 – Matriz de confusão do cenário 2 com aumento de dados.



Fonte: Autoria própria.

Figura 15 – Matriz de confusão do cenário 2 sem aumento de dados.



Fonte: Autoria própria.

# Resultados e Discussão

## Cenário 3 - Análise dos Resultados

Tabela 10 – Resultados da U-NET no cenário 3 com aumento de dados. Tabela 11 – Resultados da U-NET no cenário 3 sem aumento de dados.

Classe	Prec	Sens	F1-Score	IoU
Desenvolvida	0.89	0.81	0.85	0.73
Floresta	0.96	0.80	0.87	0.77
Sombra	0.68	0.94	0.79	0.65
Regeneração	0.86	0.64	0.73	0.58
Agricultura	0.80	0.96	0.87	0.77
Rocha	0.52	0.91	0.66	0.49
Solo Exposto	0.31	0.73	0.43	0.28
Água	0.96	0.93	0.95	0.90
Acurácia	0.81		IoU	0.65

Fonte: Autoria própria.

Classe	Prec	Sens	F1-Score	IoU
Desenvolvida	0.89	<b>0.87</b>	<b>0.88</b>	<b>0.79</b>
Floresta	0.92	<b>0.89</b>	<b>0.91</b>	<b>0.83</b>
Sombra	<b>0.87</b>	0.83	<b>0.85</b>	<b>0.73</b>
Regeneração	0.82	<b>0.88</b>	<b>0.85</b>	<b>0.74</b>
Agricultura	<b>0.86</b>	0.95	<b>0.90</b>	<b>0.82</b>
Rocha	<b>0.80</b>	0.71	<b>0.75</b>	<b>0.60</b>
Solo Exposto	<b>0.70</b>	0.42	<b>0.52</b>	<b>0.35</b>
Água	<b>0.98</b>	0.88	0.93	0.86
Acurácia	0.87		IoU	0.72

Fonte: Autoria própria.

# Resultados e Discussão

## Cenário 3 - Matriz de Confusão

Figura 16 – Matriz de confusão do cenário 3 com aumento de dados.



Fonte: Autoria própria.

Figura 17 – Matriz de confusão do cenário 3 sem aumento de dados.



Fonte: Autoria própria.

# Resultados e Discussão

## Cenário 4 - Análise dos Resultados

Tabela 12 – Resultados da SegNet no cenário 4 com *Focal Loss*.

Classe	Prec	Sens	F1-Score	IoU
Desenvolvida	0.85	0.86	0.86	0.75
Floresta	0.89	0.90	0.89	0.81
Sombra	0.89	0.74	0.81	0.68
Regeneração	0.75	0.89	0.81	0.68
Agricultura	0.85	0.85	0.85	0.74
Rocha	0.61	0.53	0.57	0.40
Solo Exposto	0.52	0.22	0.31	0.18
Água	0.98	0.43	0.60	0.42
Acurácia	0.83		IoU	0.58

Fonte: Autoria própria.

Tabela 13 – Resultados da U-NET no cenário 4 com *Focal Loss*.


Classe	Prec	Sens	F1-Score	IoU
Desenvolvida	0.90	0.86	0.88	0.79
Floresta	0.91	0.91	0.91	0.83
Sombra	0.89	0.80	0.84	0.73
Regeneração	0.80	0.88	0.84	0.72
Agricultura	0.85	0.94	0.89	0.81
Rocha	0.81	0.67	0.74	0.58
Solo Exposto	0.75	0.36	0.49	0.32
Água	0.99	0.89	0.94	0.88
Acurácia	0.87		IoU	0.71

Fonte: Autoria própria.

# Resultados e Discussão


## Cenário 4 - Matriz de Confusão

Figura 18 – Matriz de confusão do cenário 4 com *Focal Loss*.



Fonte: Autoria própria.

Figura 19 – Matriz de confusão do cenário 4 com *Focal Loss*.



Fonte: Autoria própria.

# Resultados e Discussão

## Comparação dos Resultados

Tabela 14 – Comparação dos resultados obtidos.

Cenário	Acurácia	Precisão	Sensibilidade	F1-Score	IoU
1	0.81	0.65	0.06	0.11	0.05
2	0.65	0.66	0.73	0.69	0.40
3	0.81	0.80	0.96	0.87	0.77
4	0.83	0.85	0.86	0.86	0.75

Fonte: Autoria própria.



# Conclusões

## Descrição das Conclusões Obtidas







### Lista de conclusões

- Conclusão 1.
- Conclusão 2.
- Conclusão 3.
- Conclusão 4.
- Conclusão 5.

# Referências

- ALAM, M. et al. Convolutional Neural Network for the Semantic Segmentation of Remote Sensing Images. **Mobile Networks and Applications**, v. 26, n. 1, p. 200–215, fev. 2021.
- BRESSAN, P. O. et al. Semantic segmentation with labeling uncertainty and class imbalance applied to vegetation mapping. **International Journal of Applied Earth Observation and Geoinformation**, v. 108, p. 102690, 2022. ISSN 1569-8432. DOI: <https://doi.org/10.1016/j.jag.2022.102690>. Disponível em: [↗](#).
- CHEN, W. et al. Mapping agricultural plastic greenhouses using Google Earth images and deep learning. **Computers and Electronics in Agriculture**, v. 191, p. 106552, 2021. ISSN 0168-1699. DOI: <https://doi.org/10.1016/j.compag.2021.106552>. Disponível em: [↗](#).
- CVAT.AI. **opencv/cvat: v2.4.0**. [S.l.]: Zenodo, mar. 2023. DOI: [10.5281/zenodo.7739965](https://doi.org/10.5281/zenodo.7739965). Disponível em: [↗](#).
- DE SOUZA BRITO, A. et al. Combining max-pooling and wavelet pooling strategies for semantic image segmentation. **Expert Systems with Applications**, v. 183, p. 115403, 2021. ISSN 0957-4174. DOI: <https://doi.org/10.1016/j.eswa.2021.115403>. Disponível em: [↗](#).
- DENG, J. et al. ImageNet: A large-scale hierarchical image database. In: 2009 IEEE Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2009. P. 248–255. DOI: [10.1109/CVPR.2009.5206848](https://doi.org/10.1109/CVPR.2009.5206848).
- ESRI INC. **ArcGIS Pro**. Acesso em: 24 mar 2023. 2023. Disponível em: [↗](#).
- FARHANGFAR, S.; REZAEIAN, M. Semantic Segmentation of Aerial Images using FCN-based Network. In: 2019 27th Iranian Conference on Electrical Engineering (ICEE). [S.l.: s.n.], 2019. P. 1864–1868. DOI: [10.1109/IranianCEE.2019.8786455](https://doi.org/10.1109/IranianCEE.2019.8786455).
- INC, A. **Anaconda Documentation: Release 2.0**. Acesso em: 24 mar 2023. 2023. Disponível em: [↗](#).
- LI, X. et al. Dual Cross-Entropy Loss for Small-Sample Fine-Grained Vehicle Classification. **IEEE Transactions on Vehicular Technology**, v. 68, n. 5, p. 4204–4212, 2019. DOI: [10.1109/TVT.2019.2895651](https://doi.org/10.1109/TVT.2019.2895651).

# Referências

-  LIN, T.-Y. et al. **Focal Loss for Dense Object Detection**. [S.l.: s.n.], 2017.
-  NGUYEN-KHANH, L.; NGUYEN-NGOC-YEN, V.; DINH-QUOC, H. U-Net Semantic Segmentation of Digital Maps Using Google Satellite Images. In: 2021 8th NAFOSTED Conference on Information and Computer Science (NICS). [S.l.: s.n.], 2021. P. 386–391. DOI: [10.1109/NICS54270.2021.9701566](https://doi.org/10.1109/NICS54270.2021.9701566).
-  NVIDIA CORPORATION. **CUDA Toolkit Documentation 12.1**. Acesso em: 24 mar 2023. 2023. Disponível em: [↗](#).
-  PASZKE, A. et al. Automatic Differentiation in PyTorch. In: NIPS Autodiff Workshop. [S.l.: s.n.], 2017.
-  TAN, M.; LE, Q. V. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. **CoRR**, abs/1905.11946, 2019. arXiv: [1905.11946](https://arxiv.org/abs/1905.11946). Disponível em: [↗](#).
-  VAN ROSSUM, G. **Python 3 Reference Manual**. Scotts Valley, CA: CreateSpace, 2009. ISBN 978-1441412690.

# Agradecimentos

Às organizações de fomento, pelo apoio recebido para o desenvolvimento deste trabalho e a participação neste evento:



Aos presentes, pela atenção\*.

---

\* ☐ **Declaração de Responsabilidade:** o(s) autor(es) é(são) o(s) único(s) responsável(eis) pelas informações contidas neste documento.